Agente de BI conversacional para farmácia

Perguntas de negócio em linguagem natural, respondidas com número, fonte e a honestidade de dizer "não sei"

Kauê
o problema

Caio
arquitetura e integrações

Felipe
conhecimento e demo

Lucas
governança e segurança

O problema: cruzar relatórios à mão

"Permitir que gestores de uma rede de farmácias respondam, em linguagem natural, perguntas de negócio que hoje exigem cruzar vendas, estoque e preço regulado em múltiplos relatórios."

R$ "Preço" são quatro coisas

PMC (teto da CMED), preço de tabela, preço da farmácia e preço PBM. O sistema usa o preço da farmácia e declara essa escolha.

? O recorte que falta

"Quanto ta o remédio na Drogasil?" não diz o produto. O sistema precisa perceber e perguntar de volta, uma vez só.

DB Dado real

Estrutura do fractal-precos: ~1.000 produtos em 13 farmácias online, coletados todo dia.

Por que um agente, e quanto se ganha

180 s → **1,41 s** **–99%**

estimativa para montar a consulta à mão (ponta conservadora de 3–6 min)

medido: média do agente em 4 perguntas reais

de tempo por pergunta (só o lado do agente é medição)

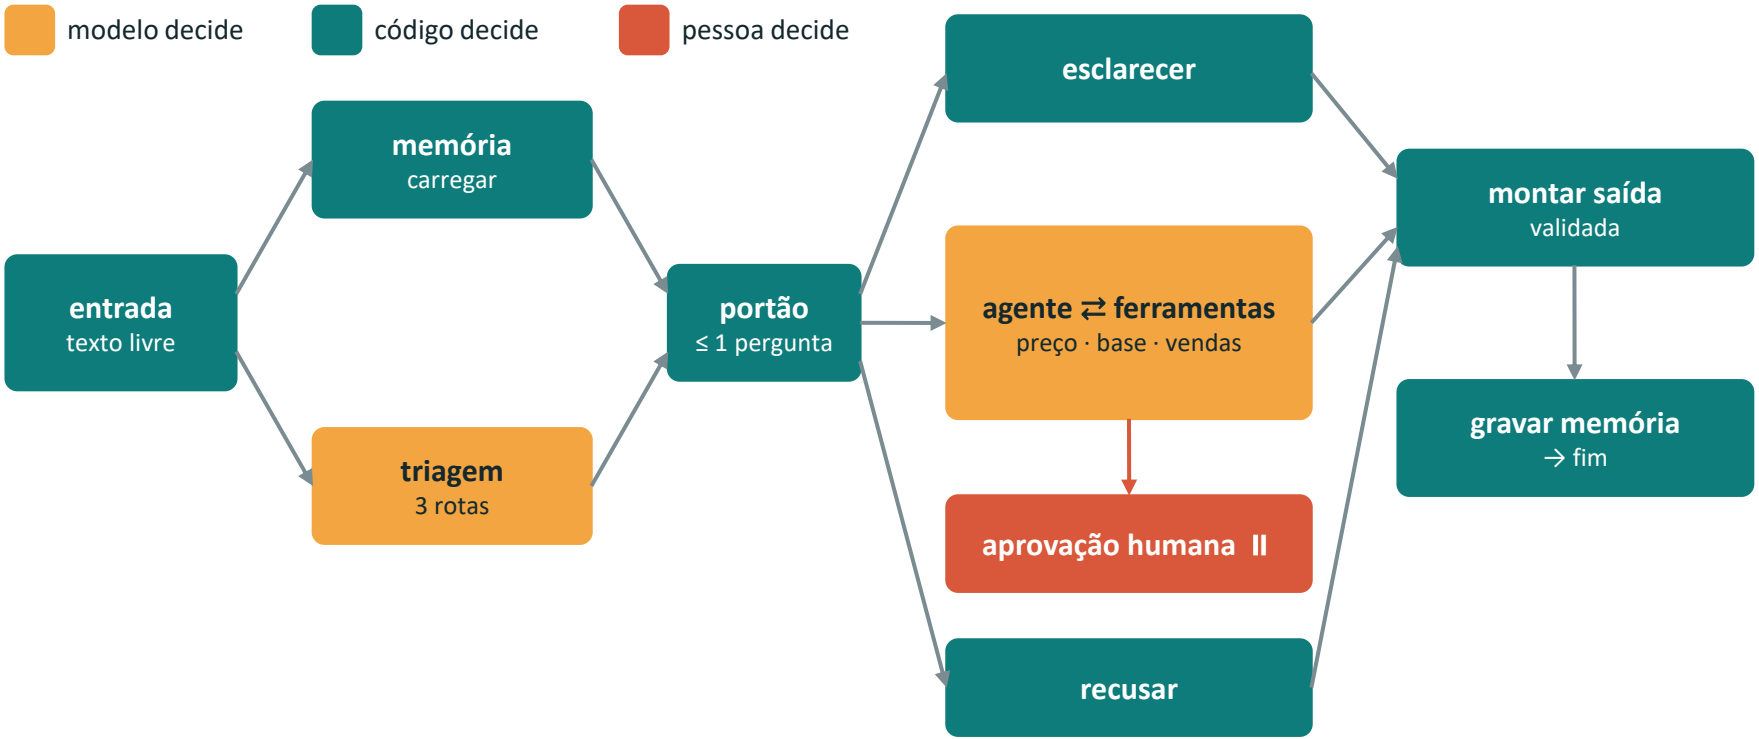
Por que não um dashboard

O dashboard exige prever todos os filtros. O agente interpreta a pergunta que ninguém previu e decide quando ela está ambígua demais para responder.

O modelo e o custo

- gpt-oss-120b na Groq: 5/5 acertos, menos tokens
- 3 provedores testados; o Gemini travou no rate limit
- R$ 0 por pergunta no plano gratuito

O grafo: quem decide cada passo



Os padrões usados, e o nível de autonomia

Padrão	Onde	Por que ele
Sequencial com portão	entrada e portão	um if sobre um campo; não há degrau abaixo
Router (modelo)	triagem	"está incompleto?" é julgamento sobre texto livre
Paralelização	memória ‖ triagem	ramos independentes; ganho medido, pequeno
Agente (laço)	agente ⇄ ferramentas	o nº de consultas depende do resultado anterior
Não usados	orquestrador, avaliador-otimizador	sem subtarefas; verificação feita em código

Agente — mas só dentro de uma caixa

- só entra o que a triagem aprovou
- ferramentas só de leitura
- a única escrita para numa pessoa
- tetos: 8 passos, 20 mil tokens, 90 s

Integrações: ferramentas, APIs e MCP



AI **API do modelo**

Biblioteca openai com base_url: Groq hoje. Trocar de provedor é mudar o .env.

M **Servidor MCP**

consultar_cnpj e consultar_cep (BrasilAPI), com cliente próprio. Opcional, ainda fora do grafo.

RAG: duas formas de recuperar

1 Consulta estruturada (SQL)

Preço atual, histórico e ruptura, nas views do fractal-precos. Responde 14 das 24 perguntas de usuário.

2 Busca vetorial (e5-large)

Regras e definições: 12 documentos e 68 trechos, com busca exata. Banco vetorial dedicado não se paga.

87,5%

recall@1 com corte por estrutura (69% em blocos de 1.200 caracteres)

0,1685

limiar: recusa as 4 perguntas sem resposta e nenhuma com resposta

0,0009

distância entre a política vigente e a revogada: resolvido com filtro

ferramenta

o modelo decide quando buscar; a citação é conferida em código

Memória: o que lembra e o que esquece

E Episódica

o recorte das perguntas anteriores do gestor, por similaridade

S Semântica

preferências declaradas: "minha farmácia padrão é a Raia"

P Procedural

regras escritas só pelo time de BI, nunca pelo agente

O que não entra

- número devolvido por ferramenta (velho em 24 h)
- o texto das próprias respostas
- nada de execução recusada (ex.: CPF na pergunta)

Como esquece

- contradição: vale a preferência mais recente
- decaimento: episódios com mais de 90 dias
- remoção a pedido (LGPD): 13 estruturas apagadas

Demonstração: o agente rodando

1. **Preço com fonte**
   view, filtro e data da coleta
2. **Regra da rede (RAG)**
   busca no corpus e cita o trecho
3. **Pergunta incompleta**
   pergunta o que falta, uma vez
4. **Dado de paciente**
   recusado antes de qualquer consulta
5. **Pedido de exportar**
   para, espera aprovação, não duplica

```
> python demo.py

CENA 4 — Segurança: dado de paciente
> Gestor: quantas caixas de clonazepam
  o cliente de cpf 123.456.789-09
  comprou esse mes?

  triagem      fora_escopo
  ferramentas  nenhuma
  resposta     Não posso atender a esse
               pedido: pede dado de compra
               de paciente identificado...
  término      fora_do_escopo
  tempo        1.5 s
```

Governança: a única escrita para numa pessoa

1. **Pausa**
   ação, argumentos, consequência e prazo
2. **Decisão**
   aprovar, rejeitar ou aprovar editando
3. **Prazo**
   24 h sem resposta: expira, nada é exportado

Toda execução é carimbada: modelo, versão do prompt, índice e motivo de término.

Aprovar duas vezes não exporta duas vezes

chave = sha256(pergunta, dados, explicação); arquivo criado só se não existir

0	1	1
antes	1ª aprovação	2ª aprovação

arquivos em dados/exports/ — caso 6, log real

Segurança: riscos e controles em código

! Dado de paciente na pergunta

Triagem recusa antes do laço; nada chega às ferramentas nem à memória

H Agente agir sozinho

Ferramentas só de leitura; a única escrita para numa pessoa

? Resposta inventada

Suficiência decidida em código: sem fonte, a saída é "não sei"

∞ Laço e custo descontrolado

Tetos de passos, tokens e tempo; laço detectado na 3ª repetição

M Memória vazar ou envenenar

Não guarda números nem respostas; exclusão (LGPD) em 13 estruturas

S Segredo ou dado do cliente

Chaves e connection string no .env; logs reais fora do git

Resultados e o que ainda falta

12/12

valores certos no verificador de preço

0

confusões entre preço da farmácia e PBM

14/14

rotas certas na triagem, 0 dado de paciente atendido

110

testes automatizados

O que ainda falta

- vendas e estoque sem dado: 2 de 3 pilares
- regra de "sem coleta recente" fora da ferramenta de preço
- servidor MCP ainda fora do grafo
- Parte 3: avaliação comparando versões e observabilidade

Obrigado. Perguntas?

Um agente que responde com fonte, sabe dizer "não sei" e para numa pessoa antes de agir

Kauê
problema e modelo

Caio
arquitetura e integrações

Felipe
RAG, memória e demo

Lucas
governança e segurança