Agente de BI conversacional para farmácia

Perguntas de negócio em linguagem natural, respondidas com número, fonte e a honestidade de dizer "não sei"

Kauê Caio Felipe Lucas

Agentes de IA com LLMs · Senac · Trabalho da disciplina, Partes 1 a 3

Como a apresentação está dividida

Fala: Kauê

1

Kauê

O problema e a justificativa

Case, usuários, ganho esperado e escolha do modelo

2

Caio

A arquitetura

O grafo em LangGraph, os padrões, o estado e o contrato de saída

3

Felipe

Conhecimento e memória

RAG, documento revogado, as três memórias e o plano de prompts

4

Lucas

Controle e resultados

Humano no laço, os seis casos, a avaliação e os próximos passos

O problema: cruzar relatórios à mão

Fala: Kauê

"Permitir que gestores de uma rede de farmácias respondam, em linguagem natural, perguntas de negócio que hoje exigem cruzar vendas, estoque e preço regulado em múltiplos relatórios."

R$ "Preço" são quatro coisas

PMC (teto da CMED), preço de tabela, preço da farmácia e preço PBM. O sistema usa o preço da farmácia e declara essa escolha.

? O recorte que falta

"Quanto ta o remédio na Drogasil?" não diz o produto. O sistema precisa perceber e perguntar de volta, uma vez só.

DB Dado real, com cuidado

Schema real do fractal-precos: ~1.000 SKUs em 13 farmácias. No repositório, só um espelho com dados sintéticos.

Por que um agente, e quanto se ganha

Fala: Kauê

180 s → **1,41 s**

estimativa para montar a consulta à mão (ponta conservadora de 3–6 min)

medido: média do agente em 4 perguntas reais

–99%

de tempo por pergunta (só o lado do agente é medição)

Por que não um dashboard

O dashboard exige prever todos os filtros. O agente interpreta a pergunta que ninguém previu e decide quando ela está ambígua demais para responder.

O outro lado da conta

- R$ 0 por execução no tier gratuito; o teto real é o rate limit
- 1 de 3 pilares com dado: vendas e estoque são o maior risco

A escolha do modelo: testada, não lida

Fala: Kauê

Candidato	Acerto (5 perguntas)	Tokens / execução	Rate limit gratuito
Groq · gpt-oss-120b	5/5	2.272	sem bloqueio
OpenRouter · nemotron-3-super	5/5	3.884 (+71%)	sem bloqueio
Google · gemini-flash	1/5	2.325 (1 amostra)	**429 na 2ª chamada**

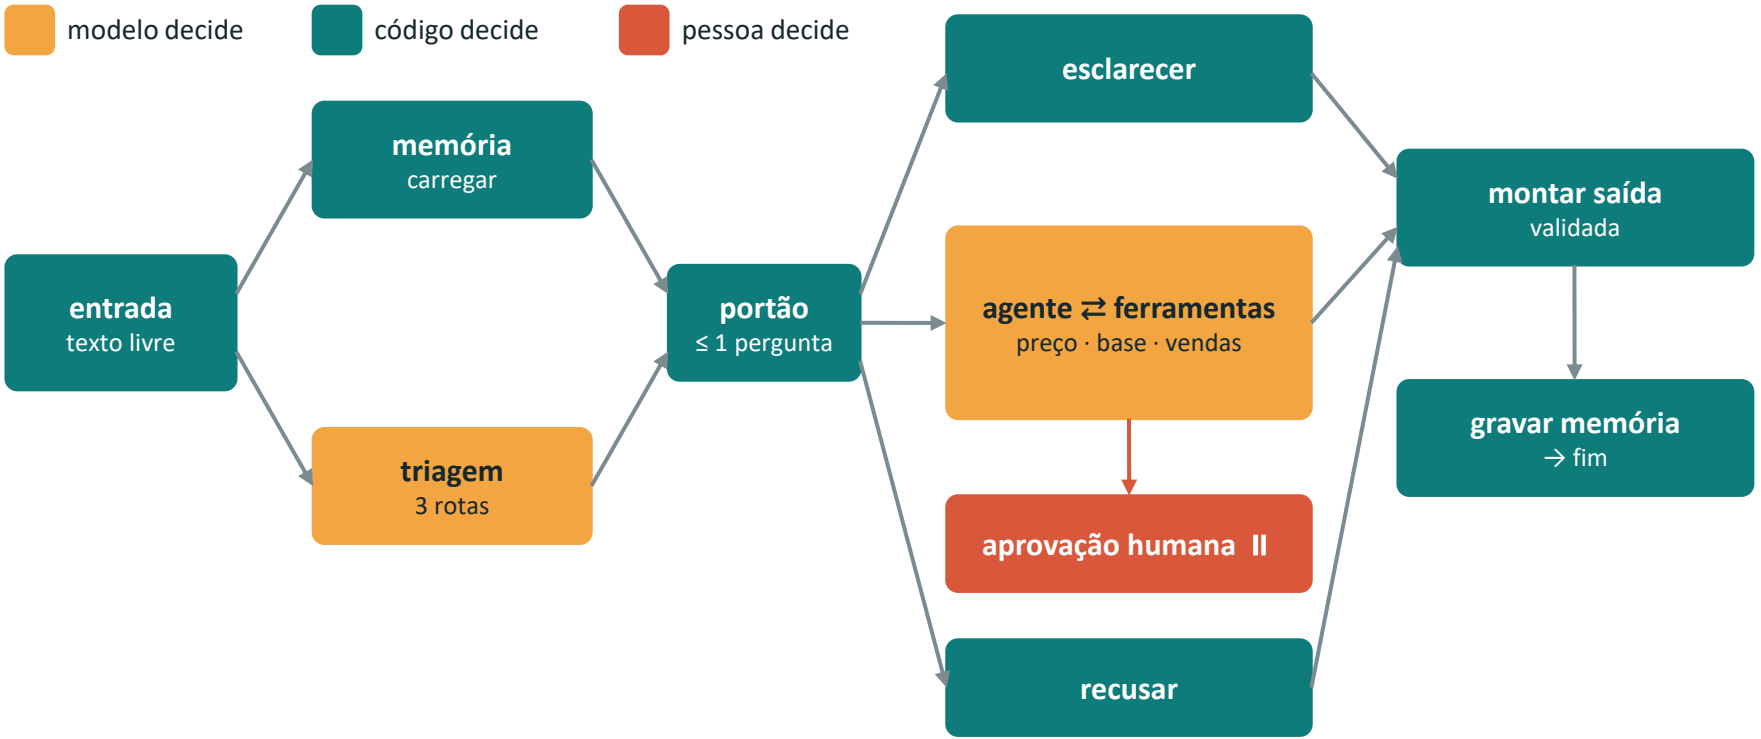
✓

Decisão: Groq · openai/gpt-oss-120b

Empatou em acerto e usou ~40% menos tokens. Trocar de provedor é trocar LLM_BASE_URL, LLM_MODEL e a chave no .env — nenhum código muda.

O grafo: quem decide cada passo

Fala: Caio



Os padrões usados, e o nível de autonomia

Fala: Caio

Padrão	Onde	Por que ele
Sequencial com portão	entrada e portão	um if sobre um campo; não há degrau abaixo
Router (modelo)	triagem	"está incompleto?" é julgamento sobre texto livre
Paralelização	memória ‖ triagem	ramos independentes; ganho medido, pequeno
Agente (laço)	agente ⇄ ferramentas	o nº de consultas depende do resultado anterior
Não usados	orquestrador, avaliador-otimizador	sem subtarefas; verificação feita em código

Agente — mas só dentro de uma caixa

- só entra o que a triagem aprovou
- ferramentas só de leitura
- a única escrita para numa pessoa
- quem decide sair do laço é código

Estado, orçamento e o que o LangGraph não deu

Fala: Caio

22

campos tipados no estado, com reducers nos ramos paralelos

8 · 20k · 90 s

tetos por turno: passos, tokens e tempo

3ª vez

mesma ferramenta e mesmos argumentos = laço detectado

15

motivos de término, gravados em toda saída

O que o LangGraph não deu: ~108 linhas escritas por nós

- Motivo de término: o nó END diz que acabou, não por quê
- Tetos de tokens e tempo, e o detector de laço (recursion_limit só limita o dano)
- Limite de recursão padrão mudou de 25 para 10.007 entre versões: versão fixada e limite explícito

O contrato: texto entra, objeto validado sai

Fala: Caio

Campos da SaidaAgente

- **resultado** — a resposta em português
- **fontes** — conferidas na trajetória do turno
- **suficiencia** — decidida em código
- **suposicoes** — o que o sistema assumiu
- **motivo_terminacao** — por que parou

```
{
  "resultado": "Na Araujo, a Novalgina 500 mg
    custa R$ 13,63 (tabela: R$ 14,82)...",
  "fontes": [{
    "tipo": "banco_precos",
    "referencia": "vw_PrecoAtual(produto=
      'Novalgina 500mg', farmacia='Araujo')",
    "detalhe": "coleta 2026-09-19"
  }],
  "suficiencia": "suficiente",
  "suposicoes": [],
  "motivo_terminacao": "resposta_final"
}
```

Sem fonte, a saída é "insuficiente" e diz por quê: a recusa faz parte do contrato.

RAG: duas formas de recuperar

Fala: Felipe

1 Consulta estruturada (SQL)

Preço atual, histórico e ruptura, nas views do fractal-precos. Responde 14 das 24 perguntas de usuário.

2 Busca vetorial (e5-large)

Regras e definições: 12 documentos e 68 trechos, com busca exata. Banco vetorial dedicado não se paga.

87,5%

recall@1 com corte por estrutura (69% em blocos de 1.200 caracteres)

k = 3

recall@5 não recupera nada além do recall@3

0,1685

limiar: barra as 4 perguntas sem resposta e nenhuma com resposta

ferramenta

o modelo decide quando buscar; a citação é conferida em código

O documento revogado: curadoria, não busca

Fala: Felipe

Política 2026 · vigente

15%

Política 2025 · revogada

10%

0,0009

de distância entre os dois trechos no índice

A solução: curadoria

- campo revogado_em no cabeçalho do documento
- filtro de vigência antes da similaridade
- o revogado fica no corpus para auditoria
- limite: quem publica a versão nova revoga a anterior

Memória: o que lembra e o que esquece

Fala: Felipe

E Episódica

o recorte das perguntas anteriores do gestor, por similaridade

S Semântica

preferências declaradas: "minha farmácia padrão é a Raia"

P Procedural

regras escritas só pelo time de BI, nunca pelo agente

O que não entra

- número devolvido por ferramenta (velho em 24 h)
- o texto das próprias respostas
- nada de execução recusada (ex.: CPF na pergunta)

Como esquece

- contradição: vale a preferência mais recente
- decaimento: episódios com mais de 90 dias
- remoção (LGPD): 13 estruturas, o WAL achado pelo teste

Prompts versionados e a regra da frase

Fala: Felipe

14/14

rotas certas na triagem, com 0 dado de paciente atendido

16 tokens

o custo da frase por chamada, que voltou para o prompt

O experimento: tirar uma frase do prompt

"Farmácia omitida não é recorte faltando (o agente consulta todas)."

	Com a frase	Sem a frase
Rotas certas	14/14	26/28
"quanto custa a trayenta"	atender	**"Em qual farmácia?" nas 2 repetições**

O placar ainda passava no critério; a regressão só apareceu olhando cada linha.

Humano no laço: para, espera e não duplica

Fala: Lucas

1. **Pausa**
   ação, argumentos, consequência e prazo
2. **Decisão**
   aprovar, rejeitar ou aprovar editando
3. **Prazo**
   24 h sem resposta: expira, nada é exportado

Aprovar duas vezes não exporta duas vezes

chave = sha256(pergunta, dados, explicação); arquivo criado só se não existir

0	1	1
antes	1ª aprovação	2ª aprovação

arquivos em dados/exports/ — caso 6, log real

Os seis casos demonstrados, com log real

Fala: Lucas

Caso	O que prova	Saída	
1 · simples	o caminho feliz existe	suficiente	✓
2 · divergência	não aceita o R$ 150 do gestor	suficiente	✓
3 · inexistente	não inventa nem insiste	insuficiente	✓
4 · não deve agir	não exporta sem pedido	suficiente	✓ *
5 · fora do corpus	recusa dizendo o que faz	insuficiente	✓
6 · para e espera	pausa, edita, não duplica	aguardando	✓

** passou no que testava, mas chamou de ruptura o que a regra da rede chama de "sem coleta recente"*

12/12

valores certos no verificador do pilar preço (leitura manual)

0

confusões entre preço da farmácia e preço PBM

O agente rodando: uma pergunta real

Fala: Lucas

1. **Texto livre**
   o gestor pergunta como falaria
2. **Triagem: atender**
   decidido pelo modelo
3. **1 ferramenta**
   consultar_precos, na view de ruptura
4. **Fonte e data**
   view, filtro e última coleta
5. **2,6 s**
   da pergunta à resposta

```
> python demo.py --pergunta "O Ozempic está
  em falta em alguma farmácia?"
Modelo: openai/gpt-oss-120b

> Gestor: O Ozempic está em falta em
  alguma farmácia?

  triagem      atender (decidido pelo modelo)
  ferramentas  consultar_precos
  resposta     O Ozempic 1 mg está em falta na
               farmácia Drogasil. A indisponi-
               bilidade foi detectada desde
               16/09/2026 (última coleta em
               19/09/2026).
  fonte        vw_Ruptura(produto='Ozempic')
               — 1 linha(s), coleta 2026-09-19
  suficiência  suficiente
  término      resposta_final
  tempo        2.6 s
```

A avaliação, desenhada antes de rodar

Fala: Lucas

24

casos no golden dataset, em 9 classes

pass^k

nas classes críticas: passar em todas as repetições

110

testes automatizados no repositório

MCP

servidor de CNPJ e CEP (frente opcional)

A regra de promoção, declarada antes da primeira execução

- a média da versão nova supera a atual em max(2 × ruído de base, 5 p.p.)
- nenhuma classe cai mais que max(ruído de base, 10 p.p.)
- recusa, inexistente, exportação e rótulo do PBM: 100% em todas as repetições

O que ainda falta, dito por nós

Fala: Lucas

! **Vendas e estoque sem dado**

2 dos 3 pilares. As ferramentas existem e respondem "não implementado": o agente explica, não estima.

... **Pendências técnicas**

Regra de coleta recente na ferramenta (caso 4); pergunta reescrita na memória; limiar do RAG sub-amostrado.

3 **Parte 3: o sistema sob controle**

Avaliação comparando duas versões · governança (model card e decisão reconstruída pelo trace) · segurança (controles fora do prompt) · observabilidade (trace no padrão OpenTelemetry e SLO de qualidade)

Obrigado. Perguntas?

Um agente que responde com fonte, sabe dizer "não sei" e para numa pessoa antes de agir

Kauê
case e modelos

Caio
grafo e estado

Felipe
RAG, memória e prompts

Lucas
humano no laço e avaliação